

Representação do Estado em Aprendizado por Reforço para Controle de Incêndios em Autômatos Celulares

Vinícius da Silva Gomes^{1,*} e Jones Oliveira de Albuquerque¹

¹Departamento de Estatística e Informática (DEINFO), Universidade Federal Rural de Pernambuco, Recife, Pernambuco, Brasil.

* Autor correspondente: vinicius.sgomes@ufrpe.br

Resumo. *Autômatos celulares (AC) descrevem a evolução espacial de sistemas locais por regras discretas de vizinhança. Neste trabalho, construímos um AC bidimensional de incêndio florestal (30 × 30) que inclui vento constante e lançamento de brasas (spotting), e formulamos a abertura de aceiros como um processo de decisão de Markov. Quatro políticas são avaliadas sob o mesmo ambiente e as mesmas sementes aleatórias: escolha aleatória de ação, heurística que abre aceiro no centroide do fogo, Q-learning tabular com observação compacta, e Proximal Policy Optimization (PPO) com observação espacial estruturada. Em 100 episódios de teste, o PPO preserva em média 61,0 % das árvores (retorno +4,79), à frente da heurística (55,9 %), do Q-learning (54,7 %) e da política aleatória (52,7 %). Testes *t* de Student pareados nas mesmas sementes confirmam diferenças significativas do PPO em biomassa frente às três alternativas ($p < 0,05$). O resultado indica que, quando o fogo pode ultrapassar barreiras por meio de brasas a sotavento, a qualidade da observação é tão determinante quanto a escolha do algoritmo de aprendizado.*

Palavras-chave: autômatos celulares; aprendizado por reforço; PPO; Q-learning; vento; spotting; controle de incêndio.

Abstract. *Cellular automata (CA) describe the spatial evolution of local systems through discrete neighborhood rules. In this work, we build a two-dimensional forest-fire CA (30 × 30) that includes constant wind and ember spotting, and we cast firebreak placement as a Markov decision process. Four policies are evaluated under the same environment and the same random seeds: random action selection, a heuristic that opens a firebreak at the fire centroid, tabular Q-learning with a compact observation, and Proximal Policy Optimization (PPO) with a structured spatial observation. Over 100 test episodes, PPO preserves on average 61,0 % of the trees (return +4.79), ahead of the heuristic (55,9 %), Q-learning (54,7 %), and the random policy (52,7 %). Paired *t*-tests on shared seeds confirm significant PPO gains in biomass against all three alternatives ($p < 0.05$). The result indicates that, when fire can overcome barriers via downwind spotting, observation quality is as decisive as the choice of learning algorithm.*

Keywords: cellular automata; reinforcement learning; PPO; Q-learning; wind; spotting; fire control.

1. Introdução

Um autômato celular é um sistema discreto no espaço e no tempo em que o estado de cada célula é atualizado por uma regra que depende apenas de uma vizinhança local [1]. A *similaridade espacial* (células próximas influenciam-se mutuamente) explica por que o fogo, o tráfego e vários processos de difusão podem ser simulados com AC de baixo custo computacional.

O modelo clássico de Drossel e Schwabl [2] já mostrou que a propagação por contato gera criticalidade auto-organizada e padrões emergentes de queima. Incêndios florestais reais, contudo, não avançam apenas por adjacência. O vento enviesa a direção da frente de fogo, e brasas transportadas pelo ar (*firebrands*) iniciam novos focos adiante da linha principal, muitas vezes além de aceiros e estradas. Uma política que reage somente à posição atual do fogo tende a falhar quando o risco decisivo já se deslocou a sotavento.

O aprendizado por reforço (RL) oferece um formalismo natural para o controle sequencial sob incerteza [4]. Neste artigo, perguntamos se um agente com observação espacial estruturada, treinado com PPO [5], aprende a antecipar o efeito do vento e das brasas e supera, no mesmo ambiente, uma heurística de centroide e um *Q-learning* tabular com observação reduzida.

2. Resultados

2.1. Desempenho médio sob sementes idênticas

A Tabela 1 e a Figura 1 resumem o desempenho em teste. O PPO obtém a maior fração média de árvores preservadas ($0,610 \pm 0,229$) e é o único método com retorno médio positivo ($+4,79 \pm 17,3$). A heurística ($0,559$) supera ligeiramente o *Q-learning* ($0,547$) e a política aleatória ($0,527$). A vantagem do PPO em biomassa é de cerca de cinco pontos percentuais sobre a heurística e de oito sobre o aleatório. Em retorno, a separação é mais nítida: enquanto as demais políticas permanecem negativas em média, o PPO cruza o zero.

Tabela 1: Desempenho médio ($\pm$ desvio padrão) em 100 episódios de teste com sementes idênticas para todas as políticas.

Política	Árvores preservadas	Retorno
Aleatório	$0,527 \pm 0,202$	$-7,46 \pm 19,5$
Q-learning	$0,547 \pm 0,213$	$-4,38 \pm 18,3$
Heurística	$0,559 \pm 0,228$	$-5,94 \pm 21,0$
PPO	$0,610 \pm 0,229$	$+4,79 \pm 17,3$




Figura 1: Comparação das quatro políticas em 100 episódios de teste. À esquerda, fração média de árvores preservadas. À direita, retorno acumulado médio. As barras de erro representam o desvio padrão.

O fato de o *Q-learning* tabular não superar a heurística é informativo. Com apenas o índice do centroide e dois bins globais, a tabela *Q* não dispõe de graus de liberdade para distinguir configurações em que o risco está a sotavento. Nessas condições, a regra fixa “sempre no centroide” já é uma boa aproximação do que o tabular consegue representar, e o custo da exploração durante o treino não se traduz em ganho claro na avaliação gulosa.

Como as sementes de teste são compartilhadas, as diferenças por episódio formam pares naturais. Aplicamos testes *t* de Student bilaterais pareados à fração de árvores preservadas, comparando o PPO a cada alternativa (Tabela 2). Todos os três contrastes são significativos a $p < 0,05$: versus aleatório, $\Delta = +0,083$, $t(99) = 3,71$, $p = 3,4 \times 10^{-4}$; versus heurística, $\Delta = +0,051$, $t(99) = 2,59$, $p = 0,011$; versus *Q-learning*, $\Delta = +0,063$, $t(99) = 2,88$, $p = 0,0049$. Os intervalos de confiança de 95 % para a diferença média excluem zero em todos os casos. Os tamanhos de efeito pareados (Cohen d_z) são modestos (0,26 a 0,37 em biomassa), coerentes com a alta variância entre mapas, mas o sinal é sistemático sob o protocolo de sementes idênticas. No retorno acumulado, as diferenças pareadas do PPO são ainda mais nítidas ($p < 10^{-4}$ frente a cada baseline). A Figura 2 mostra a distribuição das diferenças $\Delta = \text{PPO} - \text{baseline}$ por semente: a massa de pontos situa-se acima de zero em todos os contrastes, com espalhamento visível, o que ilustra o efeito sistemático porém modesto reportado na Tabela 2.

Tabela 2: Testes t de Student pareados (bilaterais) na fração de árvores preservadas: PPO versus cada política, $n = 100$ episódios com sementes 1000–1099. Δ é a diferença média (PPO – baseline); d_z é o tamanho de efeito pareado de Cohen.

Contraste	Δ	$t(99)$	p	d_z
PPO vs. aleatório	+0,083	3,71	$3,4 \times 10^{-4}$	0,37
PPO vs. heurística	+0,051	2,59	0,011	0,26
PPO vs. Q-learning	+0,063	2,88	0,0049	0,29




Figura 2: Diferenças pareadas de biomassa preservada por semente ($\Delta = \text{PPO} - \text{baseline}$) nos três contrastes. Cada ponto é um dos 100 episódios de teste com semente compartilhada. A linha horizontal em zero marca equivalência; valores positivos favorecem o PPO. Caixas mostram mediana e quartis.

2.2. Distribuição entre episódios

A Figura 3 mostra a distribuição completa da biomassa preservada. Há sobreposição entre políticas, o que é esperado: a configuração inicial dos três focos domina parte da variância (desvios padrão próximos de 0,22). Ainda assim, a massa de probabilidade do PPO desloca-se para valores mais altos, e a mediana acompanha o deslocamento da média. Os testes pareados da Tabela 2 quantificam esse deslocamento como diferença média estatisticamente detectável, e não apenas como um ou dois episódios outliers.




Figura 3: Distribuição da fração de árvores preservadas em 100 episódios com sementes compartilhadas. Violinos com caixa interna e linha de média.

2.3. Evolução do aprendizado

A Figura 4 apresenta as curvas de retorno durante o treino. No *Q-learning*, a média móvel sobe rapidamente nas primeiras centenas de episódios e depois estabiliza em patamar próximo do desempenho da heurística, coerente com a limitação da observação compacta. No PPO, o retorno por episódio é ruidoso (como é típico em RL com episódios curtos e alta variância de mapa), mas a média móvel ascende e atinge valores positivos nos episódios finais registrados (média dos últimos 50 episódios de treino aproximadamente +12), alinhada ao resultado de teste.




Figura 4: Curvas de aprendizado do retorno acumulado. À esquerda, *Q-learning* ao longo de 3000 episódios. À direita, PPO ao longo dos episódios registrados durante cerca de 200 000 passos de ambiente. Linhas claras: retorno por episódio. Linhas escuras: médias móveis.


2.4. Ilustração espacial do controle

Para tornar concreta a diferença de estratégia, a Figura 5 exhibe o estado final do mesmo mapa inicial (semente 340) sob quatro controles, além do estado inicial comum. Sem controle e sob a heurística, a maior parte da biomassa é consumida (cerca de 10 % e 12 % preservados, respectivamente). O *Q-learning* melhora parcialmente. O PPO preserva aproximadamente 91 % das árvores nesse episódio. Enfatizamos que esse episódio é um caso ilustrativo de melhor cenário (*best case*), escolhido porque o contraste espacial é visualmente claro; ele *não* é representativo da média da Tabela 1 (61 % versus cerca de 55 %–56 %). A figura serve para mostrar um regime em que antecipar o sotavento muda o desfecho qualitativo do incêndio, enquanto a inferência quantitativa permanece ancorada nas 100 sementes compartilhadas e nos testes pareados. A visualização 3D (volumes de copa, chamas e tocos sobre fundo escuro) documenta o estado da grade após a interação entre o AC e cada política.


3. Discussão

Os resultados sustentam a tese de que a diferença observada não nasce do ambiente (fixo e compartilhado), e sim da informação disponível para decidir. Com vento e brasas, a política eficaz precisa colocar combustível removido onde o fogo *estará*, não apenas onde ele *está*. A heurística e o *Q-learning* compacto operam essencialmente sobre o centroide; o PPO, ao receber densidades regionais, consegue formar uma política condicionada à geometria a sotavento.


Esse padrão ilustra um princípio clássico de RL: a representação do estado limita o desempenho tanto quanto o algoritmo de atualização [4]. Convém, contudo, precisar o que a comparação isola e o que ela mistura. O *Q-learning* opera em tabela sobre 625 estados discretos; o PPO aproxima política e valor com uma rede neural MLP sobre um vetor contínuo de 77 dimensões. Assim, o contraste não é apenas “observação compacta versus observação estruturada”: também é “tabela versus aproximação de função”. Dar as mesmas 77 dimensões ao *Q-learning* tabular exigiria discretização agressiva; um caminho mais limpo para separar observação de capacidade de modelo seria treinar, no mesmo vetor de 77 dimensões, um agente tabular aproximado (por exemplo DQN) e comparar PPO versus DQN. Não realizamos esse experimento aqui; reconhecemos a confusão parcial nas limitações e interpretamos o ganho do PPO como evidência conjunta de representação espacial mais informativa e de um otimizador capaz de explorá-la. A comparação justa que adotamos (mesmo ambiente, mesmas sementes,




(a) Estado inicial (semente 340)




(b) Sem controle



(c) Heurística



(d) Q-learning



(e) PPO

Figura 5: Renderização 3D de um episódio ilustrativo de melhor cenário (semente 340), *não* representativo da média da Tabela 1. Painel (a): configuração inicial compartilhada. Painéis (b) a (e): estado final sob cada forma de controle. A mesma física de vento e brasas atua em todos os casos.

mesmo espaço de ações) ainda isola o eixo informação/capacidade de decisão frente à física compartilhada do AC.

3.1. Limitações

A grade é moderada (30×30); o vento é constante, com reforço fixo $\text{wind_boost} = 2,0$; não há regeneração de vegetação nem fogo subterrâneo. Não exploramos sensibilidade a intensidades de vento distintas, o que seria um teste natural de robustez. A variância entre episódios permanece alta porque a geometria dos três focos iniciais muda o grau de dificuldade (desvios padrão de biomassa próximos de 0,22). Com $n = 100$ e diferenças médias de 0,05 a 0,08, o poder estatístico é limitado: os testes pareados detectam o sinal do PPO, mas os tamanhos de efeito em biomassa são modestos, e intervalos mais estreitos exigiriam mais episódios de teste. A vantagem média do PPO em biomassa é, portanto, real sob o protocolo pareado, porém numericamente modesta em pontos percentuais; o ganho em retorno é mais pronunciado. Além disso, como discutido acima, a comparação *Q-learning* versus PPO confunde parcialmente tipo de observação e capacidade de aproximação de função; um DQN (ou outro método *deep* tabular-aproximado) na observação de 77 dimensões isolaria melhor esses fatores. Essas ressalvas não anulam o resultado central: sob física com brasas, uma política com observação espacial

estruturada e aproximação neural eleva o teto de desempenho frente a baselines locais e a um tabular compacto, no mesmo ambiente.

Em síntese, implementamos um autômato celular de incêndio com vento e brasas e comparamos, sob protocolo experimental único, quatro formas de abrir aceiros. O PPO com observação espacial estruturada superou a heurística de centroide, o *Q-learning* tabular e a política aleatória tanto em biomassa preservada quanto em retorno. Além do ranking empírico, a contribuição conceitual é mais ampla: os resultados sugerem que, em problemas de controle espacial com propagação não local, investir em representações de estado mais informativas pode ser tão ou mais importante do que substituir o algoritmo de aprendizado. No presente estudo, essa ideia aparece na comparação entre uma observação compacta centrada no centroide e uma observação espacial estruturada capaz de antecipar risco a sotavento, sem alterar o ambiente físico compartilhado pelas políticas.

Como extensão natural, a inclusão de fogo subterrâneo (turfa ou húmus que rebrota após aparente extinção) aumentaria a demanda por antecipação e memória. Outras extensões diretas são: (i) variação sistemática de wind_boost e de p_{spot} ; (ii) avaliação com mais episódios de teste para estreitar intervalos; (iii) um agente DQN na mesma observação de 77 dimensões, para separar melhor representação de capacidade de modelo.

4. Métodos

4.1. Autômato celular de incêndio com vento e brasas

A floresta é representada por uma grade quadrada de lado $n = 30$. Cada célula assume um entre quatro estados: vazio, árvore, em chamas ou queimado. A atualização usa a vizinhança de Moore (oito vizinhos). No início de cada episódio, as árvores são colocadas com densidade 0,60 e são acesos três focos independentes. A probabilidade base de inflamação por contato é $p_{\text{spread}} = 0,90$.

A cada passo temporal ocorrem, nesta ordem, três processos:

1. Toda célula *em chamas* torna-se *queimada*.
2. Uma célula *árvore* pode inflamar-se se houver vizinho em chamas. A probabilidade de inflamação é maior na direção do vento (aqui o vetor constante $(0, +1)$, sentido leste, com fator de reforço 2,0) e menor a barlavento. Assim, a frente avança preferencialmente a sotavento, o que reproduz a assimetria observada em incêndios reais.
3. Com probabilidade 0,28, cada célula em chamas lança uma brasa que pousa entre 3 e 6 células a favor do vento, com pequeno desvio lateral. Se o destino contém uma árvore, esta pode inflamar-se mesmo que haja aceiro entre a origem e o destino. Esse acoplamento não local é o mecanismo que torna insuficiente a mera proteção do centroide atual.

O horizonte máximo de simulação é de 70 passos; o episódio termina antes desse limite quando não resta nenhuma célula em chamas.

4.2. Formulação como processo de decisão de Markov

O controle é modelado como um MDP compatível com a interface Gymnasium [3]. Em cada passo, o agente escolhe onde abrir um aceiro (remoção de combustível) e, em seguida, o autômato avança um passo.

O espaço de ações é discreto e relativo ao centroide do fogo. A grade é particionada em uma malha grossa 5×5 . O agente seleciona um dos nove deslocamentos dessa malha em relação à região que contém o centroide (incluindo o próprio centroide), ou a ação nula (*no-op*). Em cada ação efetiva, no máximo oito células de combustível são removidas dentro da região escolhida. Essa formulação relativa evita que o agente memorize coordenadas absolutas e concentra o problema na decisão espacial em torno do foco ativo.

A função de recompensa é deliberadamente neutra quanto à direção do vento. Ela combina: (i) um termo positivo proporcional à biomassa ainda viva; (ii) penalidade por novas células queimadas; (iii) bônus por células em chamas apagadas pelo aceiro; (iv) custo leve por cortar árvore verde; (v) no término, bônus pela fração de árvores preservadas e penalidade pela área queimada. Não existe termo que favoreça explicitamente ações a leste. Qualquer política que se antecipe a sotavento precisa descobrir essa estratégia a partir da dinâmica observada.

Protocolo de comparação justa. O ambiente físico (vento, brasas, densidade, orçamento de aceiro) é idêntico para todas as políticas. Na avaliação, as sementes aleatórias também são as mesmas. Portanto, diferenças de desempenho atribuem-se apenas ao algoritmo e à observação utilizada para decidir.

4.3. Políticas comparadas

Comparamos quatro agentes que compartilham o mesmo espaço de ações, mas diferem na forma de escolher a ação e na informação de estado disponível.

Política aleatória. Em cada passo, a ação é sorteada de modo uniforme entre as dez opções (nove deslocamentos relativos e *no-op*). Esse baseline quantifica o desempenho esperado na ausência de qualquer conhecimento da dinâmica do fogo. Como o orçamento de aceiro é limitado, ações aleatórias ocasionalmente interrompem focos, porém não organizam uma linha de defesa coerente.

Heurística de centroide. Enquanto houver células em chamas, a heurística sempre escolhe a ação relativa 0, isto é, abre aceiro na região que contém o centroide do fogo. Se o fogo se extinguiu, escolhe *no-op*. A regra é transparente e não requer treino: concentra o esforço onde a massa de fogo está agora. Sob propagação puramente local, essa estratégia é razoável. Com vento e brasas, porém, o centroide atrasa o risco verdadeiro, que se desloca a sotavento e pode ultrapassar a própria barreira que a heurística acaba de abrir.

Q-learning tabular (observação compacta). O agente tabular recebe um vetor de observação de baixa dimensão composto por três inteiros: o índice da região grossa que contém o centroide do fogo, um nível discretizado da quantidade de fogo e um nível discretizado da quantidade de árvores restantes. Com malha 5×5 e cinco níveis discretizados para a intensidade de fogo e cinco para a biomassa restante, o espaço de estados contém 625 entradas. A tabela $Q(s, a)$ é atualizada pela regra clássica de Watkins [4], com taxa de aprendizado $\alpha = 0,25$, fator de desconto $\gamma = 0,95$ e exploração ϵ -greedy decaindo até o piso 0,02. O treino durou 3000 episódios. Essa representação é suficiente para localizar o centroide e estimar a severidade global, mas não distingue densidades de combustível ou de fogo em regiões vizinhas. Em particular, o agente não “vê” um bolsão de árvores a leste do foco, onde as brasas tendem a cair.

PPO com observação espacial estruturada. O PPO [5] recebe um vetor contínuo de 77 dimensões: três mapas 5×5 com a densidade regional de células em chamas, de árvores e de células queimadas, concatenados às coordenadas normalizadas do centroide. Essa observação preserva a geometria do problema e permite correlacionar a direção do vento com padrões de risco adiante da frente de fogo. A política e o crítico são redes MLP treinadas com a implementação Stable-Baselines3 [6], usando $\gamma = 0,95$, taxa de aprendizado 3×10^{-4} , clipping 0,2 e 200 000 passos de interação com o ambiente. Como a observação já carrega a geometria regional do estado, o agente pode, em princípio, aprender a abrir aceiros à frente do centroide, e não apenas sobre ele.

Em resumo: aleatório e heurística não aprendem; o *Q-learning* aprende sobre um resumo limitado do estado; o PPO aprende sobre um mapa de densidades. O ambiente permanece fixo. O que muda é a informação e o método de decisão.

4.4. Métricas e protocolo de avaliação

Avaliamos cada política em 100 episódios de teste com sementes 1000, ..., 1099, comuns a todos os métodos. As métricas principais são:

- a fração de árvores preservadas ao fim do episódio (biomassa relativa à quantidade inicial);
- o retorno acumulado (soma das recompensas ao longo do episódio).

Reportamos média e desvio padrão. Como o protocolo é pareado por semente, também aplicamos testes *t* de Student bilaterais pareados à biomassa e ao retorno, tomando o PPO como referência frente a cada baseline, e reportamos *p*-valores, intervalos de confiança de 95 % para a diferença média e tamanhos de efeito d_z . A distribuição das diferenças por semente é exibida na Figura 2. Para visualizar a variabilidade entre focos iniciais, também examinamos a distribuição empírica da biomassa preservada. As curvas de aprendizado usam o retorno

por episódio durante o treino do *Q-learning* e do PPO. Um episódio ilustrativo de melhor cenário (semente 340) é renderizado em perspectiva 3D apenas para contrastar espacialmente o estado final; a inferência quantitativa permanece baseada nas 100 sementes compartilhadas.

Disponibilidade de dados

O código-fonte, as métricas numéricas, as figuras e as animações 3D deste estudo estão no repositório do projeto acadêmico. Os prompts empregados na assistência por inteligência artificial encontram-se na pasta de documentação do repositório.

Referências

- [1] J. L. Schiff. *Cellular Automata: A Discrete View of the World*. Wiley, 2008.
- [2] B. Drossel and F. Schwabl. Self-organized critical forest-fire model. *Phys. Rev. Lett.* **69**, 1629–1632 (1992).
- [3] M. Towers et al. Gymnasium: A standard interface for reinforcement learning environments. <https://gymnasium.farama.org/> (2023).
- [4] R. S. Sutton and A. G. Barto. *Reinforcement Learning: An Introduction*. 2nd ed. MIT Press, 2018.
- [5] J. Schulman, F. Wolski, P. Dhariwal, A. Radford and O. Klimov. Proximal Policy Optimization Algorithms. arXiv:1707.06347 (2017).
- [6] A. Raffin, A. Hill, A. Gleave, A. Kanervisto, M. Ernestus and N. Dormann. Stable-Baselines3: Reliable reinforcement learning implementations. *J. Mach. Learn. Res.* **22**(268), 1–8 (2021).