

Representação do Estado em Aprendizado por Reforço para Controle de Incêndios em Autômatos Celulares

Vinícius da Silva Gomes^{1,*} e Jones Oliveira de Albuquerque¹

¹Departamento de Estatística e Informática (DEINFO), Universidade Federal Rural de Pernambuco, Recife, Pernambuco, Brasil.

* Autor correspondente: vinicius.sgomes@ufrpe.br

Resumo. *Autômatos celulares (AC) descrevem a evolução espacial de sistemas locais por regras discretas de vizinhança. Neste trabalho, construímos um AC bidimensional de incêndio florestal (30×30) que inclui vento constante e lançamento de brasas (spotting), e formulamos a abertura de aceiros como um processo de decisão de Markov. Quatro políticas são avaliadas sob o mesmo ambiente e as mesmas sementes aleatórias: escolha aleatória de ação, heurística que abre aceiro no centroide do fogo, Q-learning tabular com observação compacta, e Proximal Policy Optimization (PPO) com observação espacial estruturada. Em 100 episódios de teste, o PPO preserva em média 61,0 % das árvores (retorno +4,79), à frente da heurística (55,9 %), do Q-learning (54,7 %) e da política aleatória (52,7 %). Testes de Student (*t* pareados) nas mesmas sementes confirmam diferenças significativas do PPO em biomassa frente às três alternativas ($p < 0,05$). O resultado indica que, quando o fogo pode ultrapassar barreiras por meio de brasas a sotavento, a qualidade da observação é tão determinante quanto a escolha do algoritmo de aprendizado.*

Palavras-chave: autômatos celulares; aprendizado por reforço; PPO; Q-learning; vento; spotting; controle de incêndio.

Abstract. *Cellular automata (CA) describe the spatial evolution of local systems through discrete neighborhood rules. In this work, we build a two-dimensional forest-fire CA (30×30) that includes constant wind and ember spotting, and we cast firebreak placement as a Markov decision process. Four policies are evaluated under the same environment and the same random seeds: random action selection, a heuristic that opens a firebreak at the fire centroid, tabular Q-learning with a compact observation, and Proximal Policy Optimization (PPO) with a structured spatial observation. Over 100 test episodes, PPO preserves on average 61,0 % of the trees (return +4.79), ahead of the heuristic (55,9 %), Q-learning (54,7 %), and the random policy (52,7 %). Paired *t*-tests on shared seeds confirm significant PPO gains in biomass against all three alternatives ($p < 0.05$). The result indicates that, when fire can overcome barriers via downwind spotting, observation quality is as decisive as the choice of learning algorithm.*

Keywords: cellular automata; reinforcement learning; PPO; Q-learning; wind; spotting; fire control.

1. Introdução

Um autômato celular é um sistema discreto no espaço e no tempo em que o estado de cada célula é atualizado por uma regra que depende apenas de uma vizinhança local [1]. A *similaridade espacial* (células próximas influenciam-se mutuamente) explica por que o fogo, o tráfego e vários processos de difusão podem ser simulados com AC de baixo custo computacional.

O modelo clássico de Drossel e Schwabl [2] já mostrou que a propagação por contato gera criticalidade auto-organizada e padrões emergentes de queima. Incêndios florestais reais, contudo, não avançam apenas por adjacência. O vento enviesa a direção da frente de fogo, e brasas transportadas pelo ar (*firebrands*) iniciam novos focos adiante da linha principal, muitas vezes além de aceiros e estradas. Uma política que reage somente à posição atual do fogo tende a falhar quando o risco decisivo já se deslocou a sotavento.

O aprendizado por reforço (RL) oferece um formalismo natural para o controle sequencial sob incerteza [4]. Neste artigo, perguntamos se um agente com observação espacial estruturada, treinado com PPO [5], aprende a antecipar o efeito do vento e das brasas e supera, no mesmo ambiente, uma heurística de centroide e um Q-learning tabular com observação reduzida.

Além de constituir um problema de controle, este estudo mostra como autômatos celulares oferecem um ambiente experimental particularmente propício para investigar algoritmos de decisão em sistemas espaciais complexos: as regras de atualização são totalmente conhecidas e auditáveis, o que permite isolar com precisão o efeito da representação de estado sobre o desempenho, algo mais difícil de garantir em ambientes de RL com dinâmica opaca.

2. Resultados

2.1. Desempenho médio sob sementes idênticas

A Tabela 1 e a Figura 1 resumem o desempenho em teste. O PPO obtém a maior fração média de árvores preservadas ($0,610 \pm 0,229$) e é o único método com retorno médio positivo ($+4,79 \pm 17,3$). A heurística ($0,559$) supera ligeiramente o *Q-learning* ($0,547$) e a política aleatória ($0,527$). A vantagem do PPO em biomassa é de cerca de cinco pontos percentuais sobre a heurística e de oito sobre o aleatório. Em retorno, a separação é mais nítida: enquanto as demais políticas permanecem negativas em média, o PPO cruza o zero.

Tabela 1: Desempenho médio ($\pm$ desvio padrão) em 100 episódios de teste com sementes idênticas para todas as políticas.

Política	Árvores preservadas	Retorno
Aleatório	$0,527 \pm 0,202$	$-7,46 \pm 19,5$
Q-learning	$0,547 \pm 0,213$	$-4,38 \pm 18,3$
Heurística	$0,559 \pm 0,228$	$-5,94 \pm 21,0$
PPO	$0,610 \pm 0,229$	$+4,79 \pm 17,3$




Figura 1: Comparação das quatro políticas em 100 episódios de teste. À esquerda, fração média de árvores preservadas. À direita, retorno acumulado médio. As barras de erro representam o desvio padrão.

O fato de o *Q-learning* tabular não superar a heurística é informativo. Com apenas o índice do centroide e dois bins globais, a tabela *Q* não dispõe de graus de liberdade para distinguir configurações em que o risco está a sotavento. Nessas condições, a regra fixa “sempre no centroide” já é uma boa aproximação do que o tabular consegue representar, e o custo da exploração durante o treino não se traduz em ganho claro na avaliação gulosa.

Como as sementes de teste são compartilhadas, as diferenças por episódio formam pares naturais. Aplicamos testes *t* de Student bilaterais pareados à fração de árvores preservadas, comparando o PPO a cada alternativa (Tabela 2). Todos os três contrastes são significativos a $p < 0,05$: versus aleatório, $\Delta = +0,083$, $t(99) = 3,71$, $p = 3,4 \times 10^{-4}$; versus heurística, $\Delta = +0,051$, $t(99) = 2,59$, $p = 0,011$; versus *Q-learning*, $\Delta = +0,063$, $t(99) = 2,88$, $p = 0,0049$. Os intervalos de confiança de 95 % para a diferença média excluem zero em todos os casos. Os tamanhos de efeito pareados (Cohen d_z) são modestos (0,26 a 0,37 em biomassa), coerentes com a alta variância entre mapas, mas o sinal é sistemático sob o protocolo de sementes idênticas. No retorno acumulado, as diferenças pareadas do PPO são ainda mais nítidas ($p < 10^{-4}$ frente a cada baseline). A Figura 2 mostra a distribuição das diferenças $\Delta = \text{PPO} - \text{baseline}$ por semente: a massa de pontos situa-se acima de zero em

todos os contrastes, com espalhamento visível, o que ilustra o efeito sistemático porém modesto reportado na Tabela 2.

Tabela 2: Testes t de Student pareados (bilaterais) na fração de árvores preservadas: PPO versus cada política, $n = 100$ episódios com sementes 1000–1099. Δ é a diferença média (PPO – baseline); d_z é o tamanho de efeito pareado de Cohen.

Contraste	Δ	$t(99)$	p	d_z
PPO vs. aleatório	+0,083	3,71	$3,4 \times 10^{-4}$	0,37
PPO vs. heurística	+0,051	2,59	0,011	0,26
PPO vs. Q-learning	+0,063	2,88	0,0049	0,29




Figura 2: Diferenças pareadas de biomassa preservada por semente ($\Delta = \text{PPO} - \text{baseline}$) nos três contrastes. Cada ponto é um dos 100 episódios de teste com semente compartilhada. A linha horizontal em zero marca equivalência; valores positivos favorecem o PPO. O losango preto indica a diferença média em cada contraste.

2.2. Distribuição entre episódios

A Figura 3 mostra a distribuição completa da biomassa preservada. Há sobreposição entre políticas, o que é esperado: a configuração inicial dos três focos domina parte da variância (desvios padrão próximos de 0,22). Ainda assim, a massa de probabilidade do PPO desloca-se para valores mais altos, e a mediana acompanha o deslocamento da média. Os testes pareados da Tabela 2 quantificam esse deslocamento como diferença média estatisticamente detectável, e não apenas como um ou dois episódios outliers.




Figura 3: Distribuição da fração de árvores preservadas em 100 episódios com sementes compartilhadas. Violinos com caixa interna e linha de média.

2.3. Evolução do aprendizado

A Figura 4 apresenta as curvas de retorno durante o treino. No *Q-learning*, a média móvel sobe rapidamente nas primeiras centenas de episódios e depois estabiliza em patamar próximo do desempenho da heurística, coerente com a limitação da observação compacta. No PPO, o retorno por episódio é ruidoso (como é típico em RL com episódios curtos e alta variância de mapa), mas a média móvel ascende e atinge valores positivos nos episódios finais registrados (média dos últimos 50 episódios de treino aproximadamente +12), alinhada ao resultado de teste.




Figura 4: Curvas de aprendizado do retorno acumulado. À esquerda, *Q-learning* ao longo de 3000 episódios. À direita, PPO ao longo dos episódios registrados durante cerca de 200 000 passos de ambiente. Linhas claras: retorno por episódio. Linhas escuras: médias móveis.


2.4. Ilustração espacial do controle

Para tornar concreta a diferença de estratégia, a Figura 5 exhibe o estado final do mesmo mapa inicial (semente 340) sob quatro controles, além do estado inicial comum. Sem controle e sob a heurística, a maior parte da biomassa é consumida (cerca de 10 % e 12 % preservados, respectivamente). O *Q-learning* melhora parcialmente. O PPO preserva aproximadamente 91 % das árvores nesse episódio. Enfatizamos que esse episódio é um caso ilustrativo de melhor cenário (*best case*), escolhido porque o contraste espacial é visualmente claro; ele *não* é representativo da média da Tabela 1 (61 % versus cerca de 55 %–56 %). A figura serve para mostrar um regime em que antecipar o sotavento muda o desfecho qualitativo do incêndio, enquanto a inferência quantitativa permanece ancorada nas 100 sementes compartilhadas e nos testes pareados. A visualização 3D (volumes de copa, chamas e tocos sobre fundo escuro) documenta o estado da grade após a interação entre o AC e cada política.


3. Discussão

Os resultados sustentam a tese de que a diferença observada não nasce do ambiente (fixo e compartilhado), e sim da informação disponível para decidir. Com vento e brasas, a política eficaz precisa colocar combustível removido onde o fogo *estará*, não apenas onde ele *está*. A heurística e o *Q-learning* compacto operam essencialmente sobre o centroide; o PPO, ao receber densidades regionais, consegue formar uma política condicionada à geometria a sotavento.


Esse padrão ilustra um princípio clássico de RL: o desempenho depende tanto da representação do estado quanto do algoritmo de aprendizado [4]. Convém, contudo, precisar o que a comparação isola e o que ela mistura. O *Q-learning* opera em tabela sobre 625 estados discretos; o PPO aproxima política e valor com uma rede neural MLP sobre um vetor contínuo de 77 dimensões. Assim, o contraste não é apenas “observação compacta versus observação estruturada”: também é “tabela versus aproximação de função”. Dar as mesmas 77 dimensões ao *Q-learning* tabular exigiria discretização agressiva; um caminho mais limpo para separar observação de capacidade de modelo seria treinar, no mesmo vetor de 77 dimensões, um algoritmo Deep Q-Network (DQN), que utiliza aproximação de função, e comparar PPO versus DQN. Não realizamos esse experimento aqui; reconhecemos a confusão parcial nas limitações e interpretamos o ganho do PPO como evidência conjunta de representação espacial mais informativa e de um otimizador capaz de explorá-la. A comparação justa que adotamos (mesmo




(a) Estado inicial (semente 340)




(b) Sem controle



(c) Heurística



(d) Q-learning



(e) PPO

Figura 5: Renderização 3D de um episódio ilustrativo de melhor cenário (semente 340), *não* representativo da média da Tabela 1. Paineis (a): configuração inicial compartilhada. Paineis (b) a (e): estado final sob cada forma de controle. A mesma física de vento e brasas atua em todos os casos.

ambiente, mesmas sementes, mesmo espaço de ações) ainda isola o eixo informação/capacidade de decisão frente à física compartilhada do AC.

3.1. Limitações

A grade é moderada (30×30); o vento é constante, com reforço fixo $\text{wind_boost} = 2,0$; não há regeneração de vegetação nem fogo subterrâneo. Não exploramos sensibilidade a intensidades de vento distintas, o que seria um teste natural de robustez. A variância entre episódios permanece alta porque a geometria dos três focos iniciais muda o grau de dificuldade (desvios padrão de biomassa próximos de 0,22). Com $n = 100$ e diferenças médias de 0,05 a 0,08, o poder estatístico é limitado: os testes pareados detectam o sinal do PPO, mas os tamanhos de efeito em biomassa são modestos, e intervalos mais estreitos exigiriam mais episódios de teste. A vantagem média do PPO em biomassa é, portanto, real sob o protocolo pareado, porém numericamente modesta em pontos percentuais; o ganho em retorno é mais pronunciado. Além disso, como discutido acima, a comparação *Q-learning* versus PPO confunde parcialmente tipo de observação e capacidade de aproximação de função; um método baseado em aproximação de função, como o DQN, na observação de 77 dimensões isolaria melhor esses fatores. Essas ressalvas não anulam o resultado central: sob física com brasas, uma política com

observação espacial estruturada e aproximação neural eleva o teto de desempenho frente a baselines locais e a um tabular compacto, no mesmo ambiente.

Em síntese, implementamos um autômato celular de incêndio com vento e brasas e comparamos, sob protocolo experimental único, quatro formas de abrir aceiros. O PPO com observação espacial estruturada superou a heurística de centroide, o *Q-learning* tabular e a política aleatória tanto em biomassa preservada quanto em retorno. Além do ranking empírico, a contribuição conceitual é mais ampla: os resultados sugerem que, no cenário estudado, em problemas de controle espacial com propagação não local, investir em representações de estado mais informativas pode ser tão ou mais importante do que substituir o algoritmo de aprendizado. No presente estudo, essa ideia aparece na comparação entre uma observação compacta centrada no centroide e uma observação espacial estruturada capaz de antecipar risco a sotavento, sem alterar o ambiente físico compartilhado pelas políticas.

Como extensão natural, a inclusão de fogo subterrâneo (turfa ou húmus que rebrota após aparente extinção) aumentaria a demanda por antecipação e memória. Outras extensões diretas são: (i) variação sistemática de wind_boost e de p_{spot} ; (ii) avaliação com mais episódios de teste para estreitar intervalos; (iii) um algoritmo DQN na mesma observação de 77 dimensões, para separar melhor representação de capacidade de modelo.

4. Métodos

4.1. Autômato celular de incêndio com vento e brasas

A floresta é representada por uma grade quadrada de lado $n = 30$. Cada célula assume um entre quatro estados: vazio, árvore, em chamas ou queimado. A atualização usa a vizinhança de Moore (oito vizinhos). No início de cada episódio, as árvores são colocadas com densidade 0,60 e são acesos três focos independentes. A probabilidade base de inflamação por contato é $p_{\text{spread}} = 0,90$.

A cada passo temporal ocorrem, nesta ordem, três processos:

1. Toda célula *em chamas* torna-se *queimada*.
2. Uma célula *árvore* pode inflamar-se se houver vizinho em chamas. A probabilidade de inflamação é maior na direção do vento (aqui o vetor constante $(0, +1)$, sentido leste, com fator de reforço 2,0) e menor a barlavento. Assim, a frente avança preferencialmente a sotavento, o que reproduz a assimetria observada em incêndios reais.
3. Com probabilidade 0,28, cada célula em chamas lança uma brasa que pousa entre 3 e 6 células a favor do vento, com pequeno desvio lateral. Se o destino contém uma árvore, esta pode inflamar-se mesmo que haja aceiro entre a origem e o destino. Esse acoplamento não local é o mecanismo que torna insuficiente a mera proteção do centroide atual.

O horizonte máximo de simulação é de 70 passos; o episódio termina antes desse limite quando não resta nenhuma célula em chamas.

4.2. Formulação como processo de decisão de Markov

O controle é modelado como um MDP compatível com a interface Gymnasium [3]. Em cada passo, o agente escolhe onde abrir um aceiro (remoção de combustível) e, em seguida, o autômato avança um passo.

O espaço de ações é discreto e relativo ao centroide do fogo. A grade é particionada em uma malha grossa 5×5 . O agente seleciona um dos nove deslocamentos dessa malha em relação à região que contém o centroide (incluindo o próprio centroide), ou a ação nula (*no-op*). Em cada ação efetiva, no máximo oito células de combustível são removidas dentro da região escolhida. Essa formulação relativa evita que o agente memorize coordenadas absolutas e concentra o problema na decisão espacial em torno do foco ativo.

A função de recompensa é deliberadamente neutra quanto à direção do vento. Ela combina: (i) um termo positivo proporcional à biomassa ainda viva; (ii) penalidade por novas células queimadas; (iii) bônus por células em chamas apagadas pelo aceiro; (iv) custo leve por cortar árvore verde; (v) no término, bônus pela fração de árvores preservadas e penalidade pela área queimada. Não existe termo que favoreça explicitamente ações

a leste. Qualquer política que se antecipe a sotavento precisa descobrir essa estratégia a partir da dinâmica observada.

Protocolo de comparação justa. O ambiente físico (vento, brasas, densidade, orçamento de aceiro) é idêntico para todas as políticas. Na avaliação, as sementes aleatórias também são as mesmas. Portanto, diferenças de desempenho atribuem-se apenas ao algoritmo e à observação utilizada para decidir.

4.3. Políticas comparadas

Comparamos quatro agentes que compartilham o mesmo espaço de ações, mas diferem na forma de escolher a ação e na informação de estado disponível.

Política aleatória. Em cada passo, a ação é sorteada de modo uniforme entre as dez opções (nove deslocamentos relativos e *no-op*). Esse baseline quantifica o desempenho esperado na ausência de qualquer conhecimento da dinâmica do fogo. Como o orçamento de aceiro é limitado, ações aleatórias ocasionalmente interrompem focos, porém não organizam uma linha de defesa coerente.

Heurística de centroide. Enquanto houver células em chamas, a heurística sempre escolhe a ação relativa 0, isto é, abre aceiro na região que contém o centroide do fogo. Se o fogo se extinguiu, escolhe *no-op*. A regra é transparente e não requer treino: concentra o esforço onde a massa de fogo está agora. Sob propagação puramente local, essa estratégia é razoável. Com vento e brasas, porém, o centroide atrasa o risco verdadeiro, que se desloca a sotavento e pode ultrapassar a própria barreira que a heurística acaba de abrir.

Q-learning tabular (observação compacta). O agente tabular recebe um vetor de observação de baixa dimensão composto por três inteiros: o índice da região grossa que contém o centroide do fogo, um nível discretizado da quantidade de fogo e um nível discretizado da quantidade de árvores restantes. Com malha 5×5 e cinco níveis discretizados para a intensidade de fogo e cinco para a biomassa restante, o espaço de estados contém 625 entradas. A tabela $Q(s, a)$ é atualizada pela regra clássica de Watkins [4], com taxa de aprendizado $\alpha = 0,25$, fator de desconto $\gamma = 0,95$ e exploração ϵ -greedy decaindo até o piso 0,02. O treino durou 3000 episódios. Essa representação é suficiente para localizar o centroide e estimar a severidade global, mas não distingue densidades de combustível ou de fogo em regiões vizinhas. Em particular, o agente não “vê” um bolsão de árvores a leste do foco, onde as brasas tendem a cair.

PPO com observação espacial estruturada. O PPO [5] recebe um vetor contínuo de 77 dimensões: três mapas 5×5 com a densidade regional de células em chamas, de árvores e de células queimadas, concatenados às coordenadas normalizadas do centroide. Essa observação preserva a geometria do problema e permite correlacionar a direção do vento com padrões de risco adiante da frente de fogo. A política e o crítico são redes MLP treinadas com a implementação Stable-Baselines3 [6], usando $\gamma = 0,95$, taxa de aprendizado 3×10^{-4} , clipping 0,2 e 200 000 passos de interação com o ambiente. Como a observação já carrega a geometria regional do estado, o agente pode, em princípio, aprender a abrir aceiros à frente do centroide, e não apenas sobre ele.

Em resumo: aleatório e heurística não aprendem; o *Q-learning* aprende sobre um resumo limitado do estado; o PPO aprende sobre um mapa de densidades. O ambiente permanece fixo. O que muda é a informação e o método de decisão.

4.4. Métricas e protocolo de avaliação

Avaliamos cada política em 100 episódios de teste com sementes 1000, ..., 1099, comuns a todos os métodos. As métricas principais são:

- a fração de árvores preservadas ao fim do episódio (biomassa relativa à quantidade inicial);
- o retorno acumulado (soma das recompensas ao longo do episódio).

Reportamos média e desvio padrão. Como o protocolo é pareado por semente, também aplicamos testes *t* de Student bilaterais pareados à biomassa e ao retorno, tomando o PPO como referência frente a cada baseline, e reportamos *p*-valores, intervalos de confiança de 95 % para a diferença média e tamanhos de efeito d_z . A

distribuição das diferenças por semente é exibida na Figura 2. Para visualizar a variabilidade entre focos iniciais, também examinamos a distribuição empírica da biomassa preservada. As curvas de aprendizado usam o retorno por episódio durante o treino do *Q-learning* e do PPO. Um episódio ilustrativo de melhor cenário (semente 340) é renderizado em perspectiva 3D apenas para contrastar espacialmente o estado final; a inferência quantitativa permanece baseada nas 100 sementes compartilhadas.

Disponibilidade de dados

O código-fonte, as métricas numéricas, as figuras e as animações 3D deste estudo estão no repositório do projeto acadêmico. Os prompts empregados na assistência por inteligência artificial encontram-se na pasta de documentação do repositório.

Referências

- [1] J. L. Schiff. *Cellular Automata: A Discrete View of the World*. Wiley, 2008.
- [2] B. Drossel and F. Schwabl. Self-organized critical forest-fire model. *Phys. Rev. Lett.* **69**, 1629–1632 (1992).
- [3] M. Towers et al. Gymnasium: A standard interface for reinforcement learning environments. <https://gymnasium.farama.org/> (2023).
- [4] R. S. Sutton and A. G. Barto. *Reinforcement Learning: An Introduction*. 2nd ed. MIT Press, 2018.
- [5] J. Schulman, F. Wolski, P. Dhariwal, A. Radford and O. Klimov. Proximal Policy Optimization Algorithms. arXiv:1707.06347 (2017).
- [6] A. Raffin, A. Hill, A. Gleave, A. Kanervisto, M. Ernestus and N. Dormann. Stable-Baselines3: Reliable reinforcement learning implementations. *J. Mach. Learn. Res.* **22**(268), 1–8 (2021).